BIG DATA COMPETITION 2026

GRIT

Group-verified, Rank-ordinal, Instance-pooled, Type-conditioned Network

untuk Klasifikasi Ganda Jenis Bencana dan Tingkat Kerusakan dari Citra

BDC12 | NamaTim | Institut Teknologi Bandung

Riantama Putra

Farrel Athalla Putra

Ayu Nagita Cahya

Pemahaman Masalah

Statistik Utama

3.176+
Bencana di Indonesia 2025 (BNPB)

99%
Bencana hidrometeorologi

281.199
Rumah rusak akibat bencana

12,12 Juta
Warga menderita dan mengungsi

Dibutuhkan framework yang akurat, sadar urutan tingkat kerusakan, dan siap dipakai tim tanggap darurat

Three Big Problems

Penilaian Masih Subjektif

Penilaian kerusakan masih bergantung pada observasi surveyor, sehingga hasilnya dapat berbeda antarpenilai.

Karakter Kerusakan Berbeda

Setiap jenis bencana memiliki indikator kerusakan yang berbeda dan sering hanya terlihat pada bagian tertentu dari citra.

Tingkat Kerusakan Bersifat Berurutan

Kategori ringan–sedang–berat memiliki hubungan bertingkat yang perlu dipahami oleh model, bukan sekadar dianggap sebagai kelas terpisah.

Metrik Evaluasi

$$F1_{\text{Micro}} = \frac{2TP_{\text{micro}}}{2TP_{\text{micro}} + FP_{\text{micro}} + FN_{\text{micro}}}$$

BIG DATA COMPETITION 2026

Tinjau Kilas Dataset

- Banjir
- Gempa Bumi
- Kebakaran

- Ringan
- Sedang
- Berat

17.482
Train

450
Test

jenis : Banjir
kerusakan : Berat

Workflow Diagram

DATASET

Dataset Klasifikasi Bencana

Berisi 17.482 citra bencana alam (banjir, gempa bumi, kebakaran) dengan label jenis dan tingkat kerusakan.

EKSPLORASI AWAL

Analisis Kualitas Data

Identifikasi kualitas label, resolusi, format, dan potensi duplikasi pada dataset.

PREPARASI DATA

Deduplikasi dan Pengelompokan Adegan

Melakukan penghapusan duplikat dan pengelompokan adegan untuk cegah kebocoran.

Cleaned Dataset

EKSPLORASI LANJUTAN

Analisis Karakteristik Data

Analisis pola ketidaksepakatan anotator dan konsentrasi bukti kerusakan pada citra.

PREPROCESSING

Resize dan Augmentasi

Standardisasi ukuran 384x384 piksel dan augmentasi ***MixUp***, ***RandomErasing***, dan ***Gaussian noise***.

SKEMA VALIDASI

Train | Val

Strategi Pembagian Data

Menggunakan pengelompokan adegan (***scene-grouped***) untuk mencegah kebocoran data antar split.

PENGEMBANGAN MODEL

DINOv3 – ViT

***Fine-Tuning* Kepala Ganda**

Fine-tuning DINOv3 ViT-7B/16 dengan kepala jenis dan kerusakan, ***FiLM***, dan target ordinal.

BENCHMARKING

Micro F1-Score

Evaluasi Performa Model

Pengukuran performa model menggunakan metrik klasifikasi dan visualisasi prediksi.

BEST MODEL

Pemilihan Model Terbaik

Memilih bobot kombinasi kepala dengan performa validasi terbaik untuk analisis hasil pengujian.

ANALISIS PASCA

Analisis Hasil dan Keterbatasan

Analisis batas akurasi kelompok adegan, generalisasi model, dan keterbatasan inferensi.

Generated Final Prediction

```
ID,Target
1_jenis,BANJIR
1_kerusakan,SEDANG
2_jenis,GEMPA BUMI
```

Mempercepat Asesmen Pascabencana

Mendukung Prioritas Tanggap Darurat

Meningkatkan Keandalan Prediksi

Exploratory Data Analysis

1

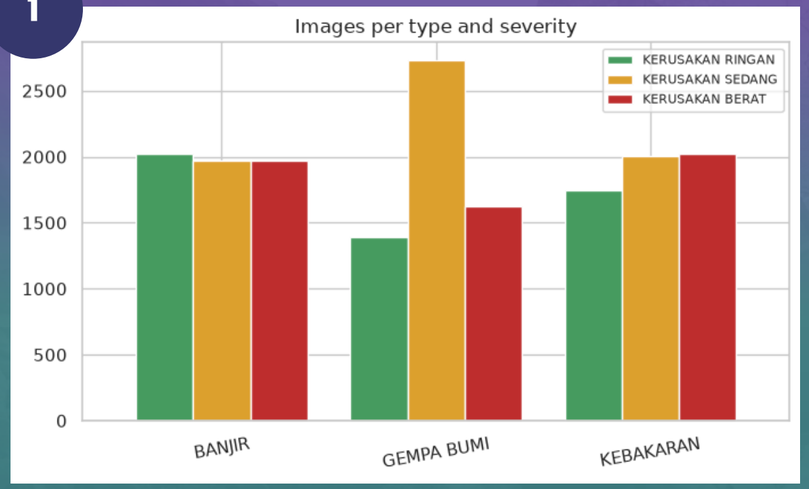

Key Takeaway

Distribusi kelas tidak merata **(rasio 1,96×)**, sehingga diperlukan metode untuk menangani proporsi tiap kombinasi seperti ***stratified sampling.***

2

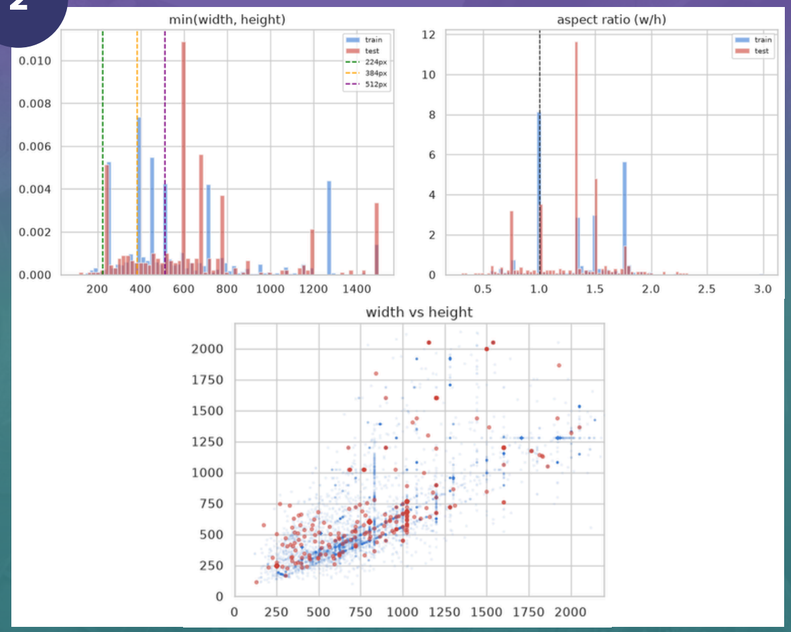

Key Takeaway

Karakteristik resolusi train–test **konsisten**, dengan median rasio aspek **4:3** dan mayoritas citra beresolusi memadai, sehingga input **384×384** sudah representatif tanpa perlu upscaling berlebihan.

3

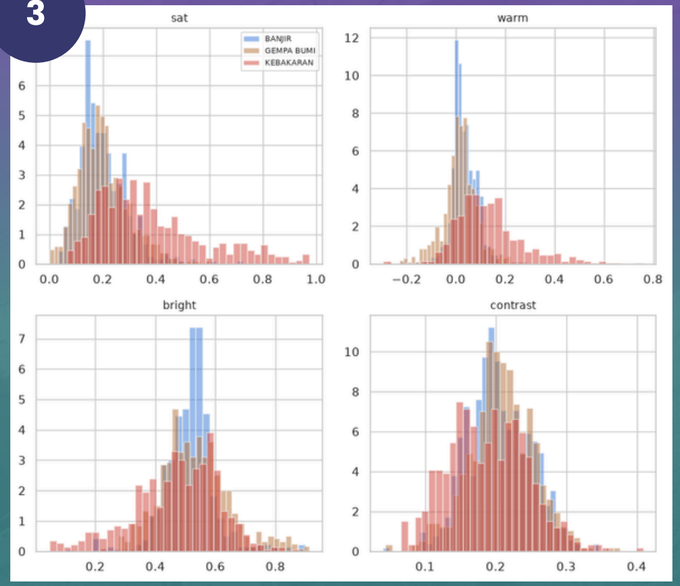

Key Takeaway

Sinyal warna **efektif** membedakan **jenis bencana**, sehingga augmentasi warna perlu dibatasi agar informasi penting tidak hilang.

Exploratory Data Analysis

4

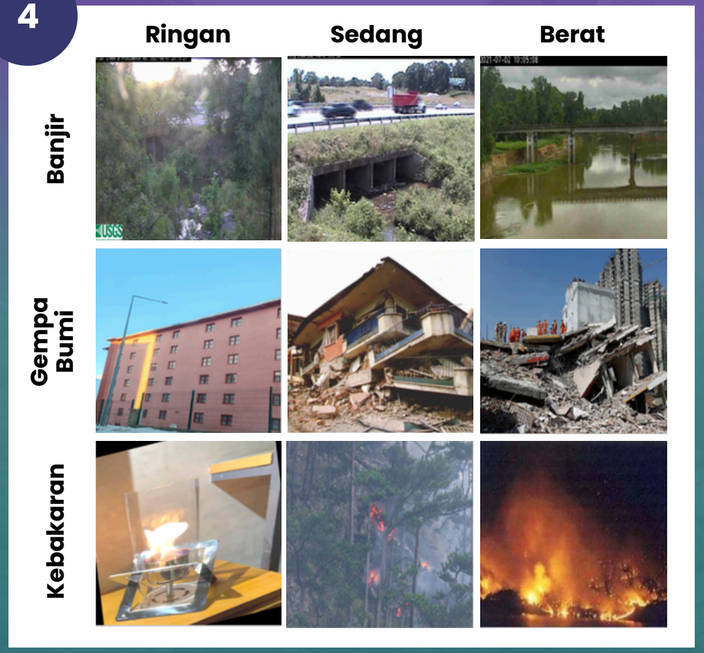

Key Takeaway

Indikator kerusakan **berbeda** pada tiap jenis bencana, sehingga diperlukan model yang mempelajari **kombinasi** jenis–tingkat kerusakan secara spesifik.

5

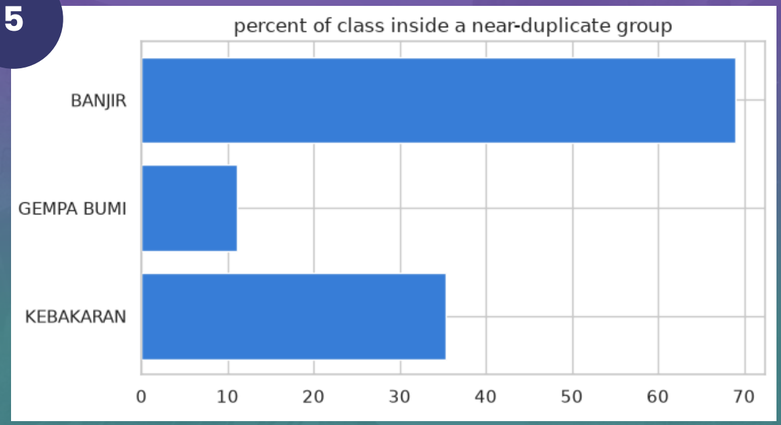

Frame from a video!

Perceptual Hash

Key Takeaway

Banyak citra berasal dari **scene yang nyaris identik** (~38%), sehingga random split berisiko menyebabkan kebocoran data dan perlu diganti dengan **scene-grouped split.**

6

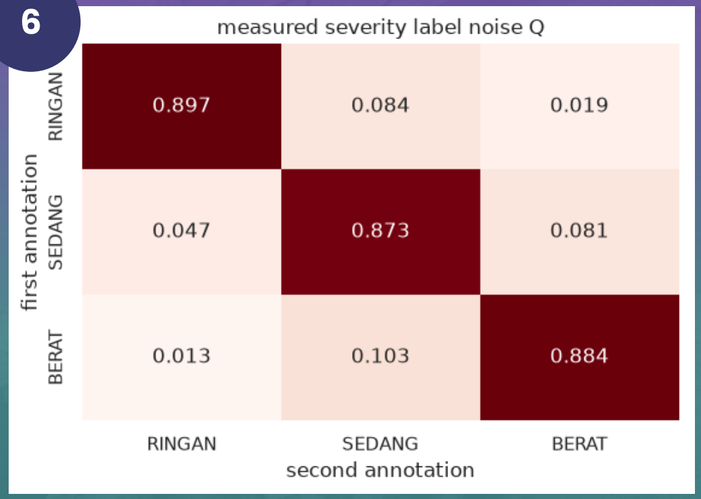

[0 , 1 , 0] → [0,06 , 0,88 , 0,06]

label kerusakan

Key Takeaway

Perbedaan label antar-anotator umumnya hanya satu tingkat, sehingga target perlu mempertimbangkan **kedekatan antarlevel kerusakan**, bukan sekadar one-hot.

Preprocessing

Original Photo

Normalized RGB
Mencegah munculnya artefak hitam yang dapat menjadi sinyal palsu.

Resize 384x384
Sesuai dengan karakteristik resolusi mayoritas data dan standar computer vision

Rotation ±10°
Metode *inscribe* agar tidak menghasilkan sudut hitam pada citra.

Random horizontal flip (p=0.5)
Meningkatkan variasi orientasi citra.

Color Jitter
(hue ≤ 0.02) agar sinyal warna tidak hilang

Gaussian Sensor Noise
Model bisa "curang" pakai noise sebagai petunjuk label.

MixUp no CutMix
Meningkatkan generalisasi

Modelling

DINOv3

40 blocks
hidden 4096
fine-tune last 6

Multi-instance pooling

CLS token
Mean pooling
Gated attention
Top-k 10% patch

Task Heads

Jenis head
Joint 9-logit head
Severity categorical
Severity ordinal

Final Outputs

Prediksi jenis
Prediksi kerusakan
Kalibrasi posterior
Ensemble severity

9-logit joint head

	Ringan	Sedang	Berat
Ban			
Gem			
Keb			

Ordinal-aware severity

Loss sadar urutan: SORD target + CORN/CORD thresholds

Scene-grouped validation

Satu adegan tetap di fold yang sama untuk cegah leakage

Evaluation

Model	Tipe	Acc Jenis	Acc Kerusakan	Micro F1
DINOv3	**ViT**	**0.9957**	**0.7669**	**0.8813**
SigLIP	ViT	0.9931	0.7291	0.8611
ConvNeXt	CNN	0.9901	0.6935	0.8418
ViT (ImageNet-21k)	ViT	0.9898	0.6844	0.8371
EfficientNet	CNN	0.9884	0.6678	0.8281
ResNet	CNN	0.9862	0.6512	0.8187

DINOv3

Strategi Split	Acc. Jenis	Acc. Kerusakan	Micro F1	Public F1	Private F1
Random Split	0.9957	0.7669	0.8813	0.807	0.825
Scene-Grouped	**0.9962**	**0.7846**	**0.8904**	**0.907**	**0.904**

Confusion Matrix

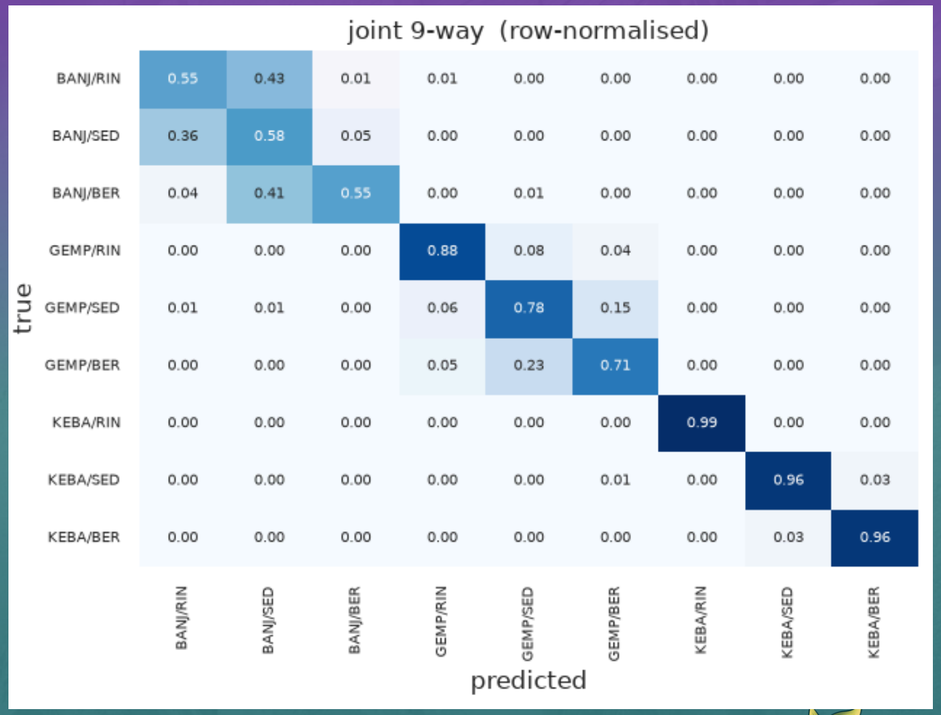

DINOv3 menjadi model terbaik dengan Micro F1 validasi 0.8813, mengungguli backbone lain dalam klasifikasi jenis dan tingkat kerusakan.

Scene-Grouped Split terbukti lebih andal karena mengurangi kemungkinan model "menghafal" scene yang sama antara data latih dan validasi

Explainable AI

Attention map menunjukkan bahwa model berfokus pada hal yang tepat, seperti air, bangunan, api

Take Aways

1. Tahap **preparasi data** seperti deduplikasi, pengelompokan adegan (scene-grouping), dan standardisasi ukuran citra berperan **penting** dalam mencegah kebocoran data dan menjaga kestabilan proses pelatihan.

2. Arsitektur **DINOv3** dengan kepala klasifikasi ganda menunjukkan performa **lebih baik** dalam membedakan jenis bencana dan tingkat kerusakan sekaligus, sehingga dipilih sebagai model **terbaik**.

3. **Scene-Grouped Split** menghasilkan evaluasi yang lebih realistis karena mencegah model menghafal adegan yang sama antara data latih dan validasi.

4. Model yang dikembangkan memberikan standar **akurasi tinggi** untuk klasifikasi ganda jenis dan tingkat kerusakan bencana, menjadi fondasi kuat bagi sistem **asesmen pascabencana**. Potensi ini dapat dieksplorasi lebih lanjut untuk mendukung inferensi secara *real-time* pada tanggap darurat lapangan.

BIG DATA COMPETITION 2026

Terima Kasih!

BDC12 | NamaTim | Institut Teknologi Bandung

Appendix A. Arsitektur Model

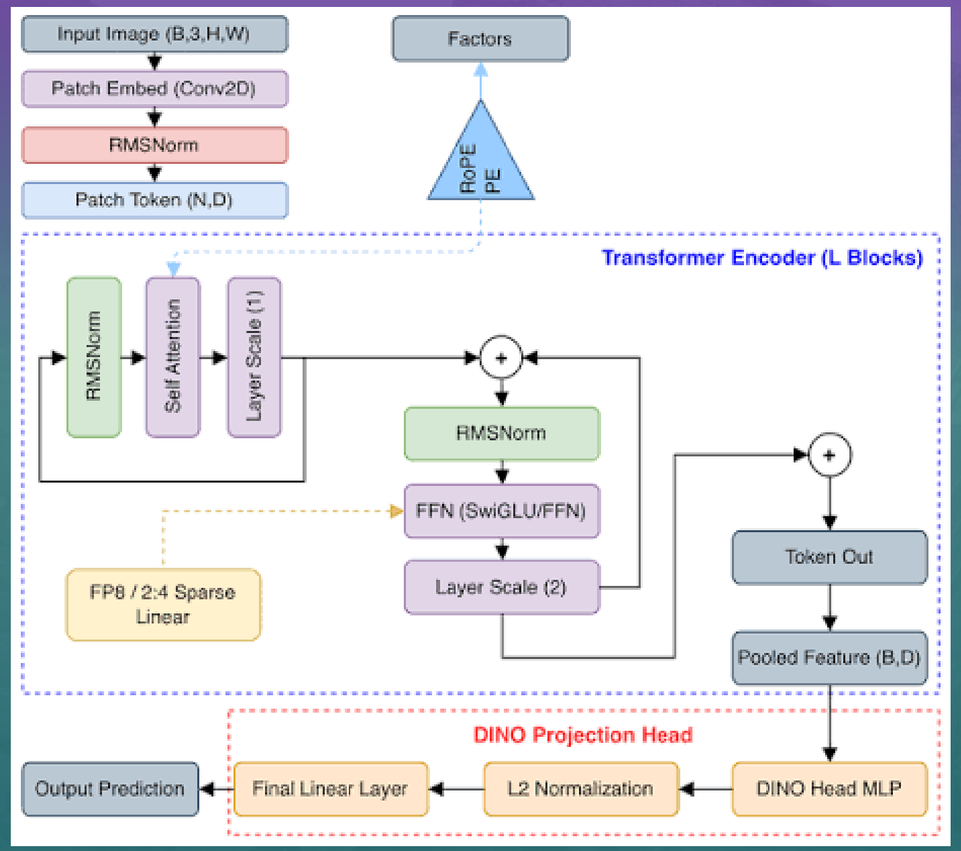

DINOv3 Architecture

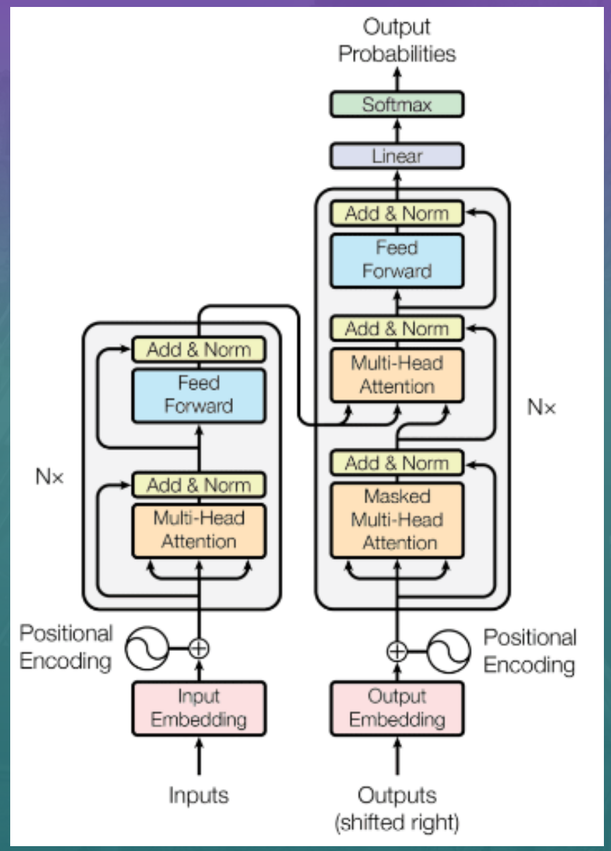

Transformer Architecture

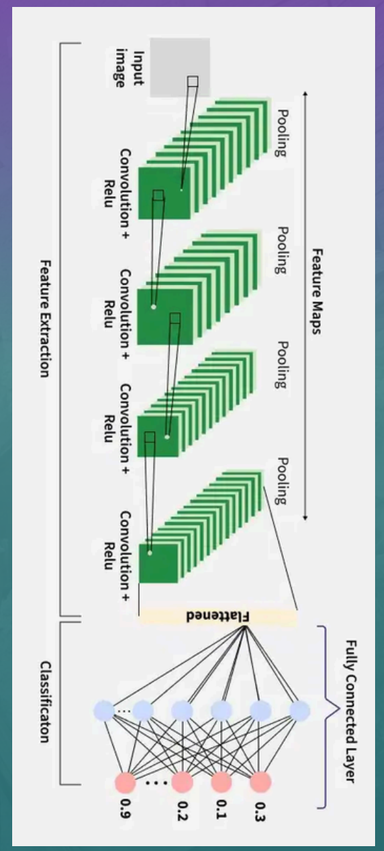

CNN Architecture

BIG DATA COMPETITION 2026

Appendix B. Why CNN Tidak Dipilih sebagai Final?

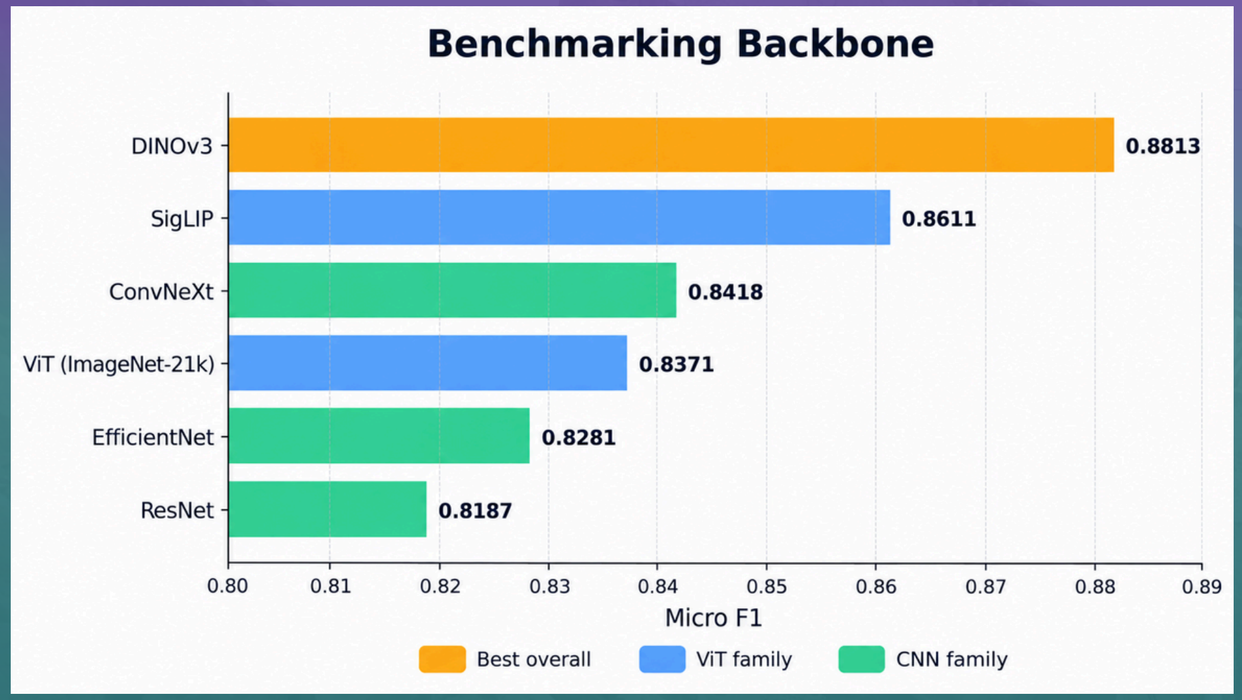

1 Butuh Konteks Global

Banjir, gempa, dan kebakaran dibaca dari relasi seluruh scene, bukan patch kecil saja

2 Bukti Kerusakan Bisa Lokal

Retakan, puing, atau titik api kecil mudah hilang kalau fitur terlalu dirata-ratakan

3 Severity Bersifat Ordinal

Ringan → Sedang → Berat perlu dimodelkan sebagai urutan, bukan tiga kelas tak terkait

Final model dipilih karena lebih cocok untuk kombinasi konteks global, bukti lokal, dan target ordinal

GRIT menjawab ini lewat self-attention + multi-instance pooling + 9-logit joint head + ordinal severity

Appendix C. Why Near-Duplicate Tidak Dihapus?

~38%
citra berada dalam scene-group multi-image

~1/3
validasi akan bocor bila split acak

1 scene = 1 fold
semua near-duplicate masuk fold yang sama

Keputusan akhir, yaitu Near-duplicate tetap dipertahankan saat training, TAPI dipakai sebagai GROUP saat validasi

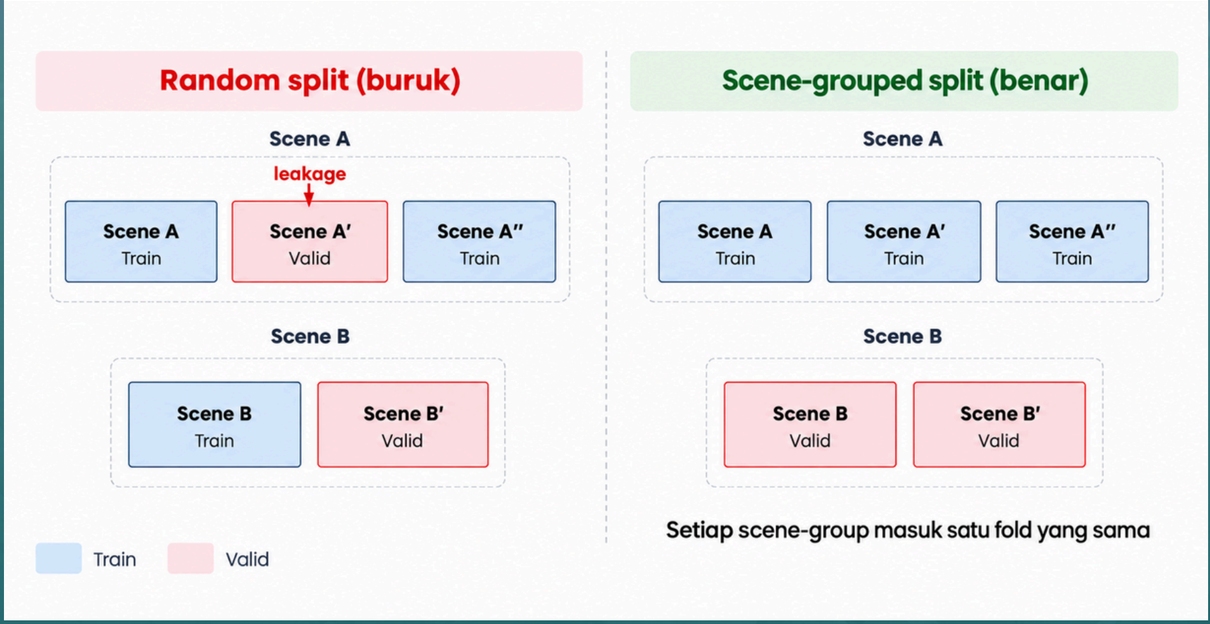

Kalau dihapus, apa masalahnya?

- Distribusi sumber bisa berubah dan makin jauh dari data uji
- Scene valid yang memang mirip ikut terbuang, padahal tetap informasi sah
- Konflik label tidak hilang; hanya disembunyikan dari evaluasi
- Lebih fair mempertahankan data, lalu mengukur dengan grouped split